4 MAI - 5JUIN
SESSION 2025-2026

ZHANG
LUC

CONCEPTION ET DÉVELOPPEMENT BACK-END D'UN MOTEUR D'ANALYSE DE DONNÉES CRYPTOGRAPHIQUES.

Assistant Développeur Data & Back-End

ZENG
EXPERTISE

SOMMAIRE

PARTIE 1 : PRÉSENTATION DE L'ENTREPRISE (La Fiche d'Identité) 4

1.1 Fiche d'identité : ZENG Expertise 4

1.2 Historique et organisation 5

1.3 Métier, secteur et concurrents 5

PARTIE 2 : ENVIRONNEMENT TECHNIQUE ET MÉTHODOLOGIE 6

2. Environnement technique et méthodologie 6

2.1 Les outils et langages 6

2.2 Méthodologie et bonnes pratiques 7

PARTIE 3 : MES MISSIONS DE DÉVELOPPEMENT BACK-END ET DATA 7

3.1 Conception du schéma SQL et exploration des données (Tasks 10 et 10.1) 7

3.2 Développement du pipeline d'extraction ETL (Task 11) 8

3.3 Intégration de l'intelligence artificielle : génération des embeddings (Task 12)9

3.4 Architecture et optimisation des index SQL (Task 13) 9

3.5 Interface de démonstration CLI (Task 13.5) 10

3.6 Développement d'un moteur de recherche hybride (Task 16) 11

Partie 4: Documentation Technique et Transfert de Compétences 12

Partie 5: Rigueur du Versioning et Résolution de Conflits 12

Partie 6: L'Intelligence Artificielle comme outil de développement 13

CONCLUSION 14

RAPPORT DE STAGE

Actuellement en première année de BTS Services Informatiques aux Organisations (SIO), option Solutions Logicielles et Applications Métiers (SLAM), je souhaite orienter ma carrière vers le domaine de la data et IA. Mon objectif est de devenir Data Analyst, puis d'évoluer vers le métier de Data Scientist avec une spécialisation en Intelligence Artificielle et en Machine Learning. Après l'obtention de mon BTS, je prévois de poursuivre mes études en Licence Professionnelle, en BUT ou au sein d'une école d'ingénieurs afin d'approfondir mes compétences.

Dans cette perspective, j'ai recherché un stage me permettant de découvrir concrètement le secteur de l'ingénierie des données. J'ai ainsi eu l'opportunité d'effectuer ma première période de formation en milieu professionnel chez ZENG Expertise, un cabinet de conseil spécialisé dans le Data Engineering et les solutions d'intelligence artificielle.

Au cours de ce stage, j'ai travaillé en étroite collaboration avec mon tuteur sur un projet de preuve de concept (Proof of Concept – PoC). L'objectif était de développer un outil capable d'analyser des données liées aux cryptomonnaies à partir d'informations historiques, afin d'en faire, à terme, un possible service destiné aux clients du cabinet. Cette expérience m'a permis de découvrir les principes de fonctionnement d'un système RAG (Retrieval-Augmented Generation) et de participer à plusieurs étapes essentielles du projet. J'ai notamment contribué à la conception de la base de données SQL, au développement du pipeline de traitement des données, à la génération d'embeddings vectoriels, à l'optimisation des requêtes ainsi qu'à l'intégration d'API d'intelligence artificielle.

Dans ce rapport, je présenterai tout d'abord le cabinet ZENG Expertise ainsi que son activité. Je décrirai ensuite l'environnement technique dans lequel j'ai évolué avant de détailler les différentes missions qui m'ont été confiées. Enfin, j'expliquerai les compétences que j'ai développées au cours de cette expérience, aussi bien sur le plan technique que dans l'application des bonnes pratiques du développement logiciel.

PARTIE 1 : PRÉSENTATION DE L'ENTREPRISE (LA FICHE D'IDENTITÉ)

1.1 FICHE D'IDENTITÉ : ZENG EXPERTISE

Fiche d'identité de l'entreprise :

- **Raison sociale** : ZENG Expertise
- **Forme juridique :** SASU
- **Date de création :** 2021
- **Dirigeant / Fondateur :** David ZENG, Consultant Data Senior
- **Siège social (Adresse) :** 99 Rue Garibaldi 69006 Lyon 6e Arrondissement
- **Numéro SIRET :** 95150511400011
- **Secteur d'activité :** Ingénierie des données et Intelligence Artificielle
- **Cœur de métier :** Architecture de bases de données, développement d'outils analytiques et intégration de modèles IA (RAG)
- **Taille de l'entreprise :** Structure indépendante
- **Clientèle cible :** Secteurs de la banque et de la finance
- **Modalité de travail :** En distanciel

1.2 HISTORIQUE ET ORGANISATION

Le cabinet ZENG Expertise a été fondé en 2021 par M. David ZENG, consultant senior spécialisé dans l'ingénierie des données. Il s'agit d'une structure indépendante à taille humaine, dont l'organisation repose sur un fonctionnement entièrement en télétravail. Durant la période de stage, l'organisation se limitait à une collaboration entre le dirigeant et stagiaire, permettant un suivi régulier et un accompagnement personnalisé.

1.3 MÉTIER, SECTEUR ET CONCURRENTS

L'activité principale de ZENG Expertise est centrée sur l'ingénierie des données (Data Engineering). Le cabinet accompagne ses clients dans la conception d'architectures de bases de données, le développement de solutions d'analyse de données et l'intégration de modèles d'intelligence artificielle. Ses prestations couvrent l'extraction, le traitement et l'exploitation de données, l'optimisation des performances des bases de données ainsi que la mise en œuvre de solutions algorithmiques adaptées aux besoins des entreprises.

Le cabinet intervient principalement auprès d'acteurs des secteurs bancaire et financier, où la gestion de grands volumes de données et la performance des systèmes d'information représentent des enjeux majeurs. Dans ce domaine, la concurrence est principalement constituée des Entreprises de Services du Numérique (ESN) ainsi que des cabinets de conseil spécialisés dans les technologies de la donnée et de l'intelligence artificielle.

L'intégration au sein de cette structure a constitué une expérience particulièrement enrichissante. Le fonctionnement en effectif réduit a favorisé un accompagnement direct par un professionnel expérimenté du domaine, tout en permettant de participer à l'ensemble des étapes du projet. Cette organisation a également permis de développer une plus grande autonomie et de découvrir les exigences attendues dans un environnement professionnel, notamment en matière de qualité du code, d'optimisation des performances, de respect des bonnes pratiques de développement, comme le principe de responsabilité unique (*Single Responsibility Principle*), gestion de projet et la communication en anglais technique.

Cette première expérience professionnelle a ainsi représenté une opportunité de mettre en pratique les connaissances acquises en formation tout en découvrant les méthodes de travail et les standards appliqués dans le domaine du Data Engineering.

PARTIE 2 : ENVIRONNEMENT TECHNIQUE ET MÉTHODOLOGIE

2. ENVIRONNEMENT TECHNIQUE ET MÉTHODOLOGIE

Afin de mener à bien le développement de cet outil d'analyse des cryptomonnaies, il a fallu s'intégrer à un environnement de travail nouveau, mais dont certains outils étaient déjà connus grâce à la formation. Ce stage a permis de découvrir des technologies largement utilisées dans le domaine du Data Engineering ainsi que des méthodes de travail proches de celles rencontrées en entreprise.

2.1 LES OUTILS ET LANGAGES

Plusieurs technologies ont été utilisées tout au long du projet :

- **Python** a constitué le langage principal pour développer la logique métier, communiquer avec les API d'intelligence artificielle et mettre en place les différents scripts de traitement des données.

- **PostgreSQL**, a été utilisé pour concevoir la base de données, créer les tables et écrire les requêtes nécessaires à l'exploitation des données. Associé à l'extension **pgvector**, a servi de système de gestion de base de données afin de stocker aussi bien les données classiques que les embeddings vectoriels.

- **Visual Studio Code** a été utilisé comme environnement de développement, tandis que **Ghostty** offrait un terminal plus fluide et plus agréable pour travailler quotidiennement.

- **Tailscale** assurait un accès sécurisé aux ressources distantes de l'entreprise.

- Un **Raspberry Pi** faisait office de serveur pour certains services du projet.

- Enfin, **Git** et **GitHub** ont été utilisés pour le suivi du code source. Le développement était organisé par vagues (*waves*) et chaque évolution était associée à un ticket précis afin d'assurer un suivi rigoureux des tâches.

2.2 MÉTHODOLOGIE ET BONNES PRATIQUES

Le stage s'est déroulé dans un fonctionnement proche de celui d'une équipe de développement. Chaque journée débutait par un *daily meeting*, permettant de faire le point sur l'avancement du projet, les difficultés rencontrées et les objectifs de la journée.

Au fil du stage, il a également fallu adopter les bonnes pratiques utilisées dans un contexte professionnel. Une attention particulière était portée à la qualité du code, notamment en appliquant le principe de responsabilité unique (*Single Responsibility Principle*) afin que chaque fonction remplisse un rôle bien défini. Les clés d'API étaient sécurisées à l'aide de fichiers d'environnement (*.env*), tandis que chaque fonctionnalité développée faisait l'objet d'une documentation technique (*User Guide*, *Technical Docs*). Cette manière de travailler a permis de mieux comprendre l'importance d'un code maintenable, documenté et facilement réutilisable par d'autres développeurs.

PARTIE 3 : MES MISSIONS DE DÉVELOPPEMENT BACK-END ET DATA

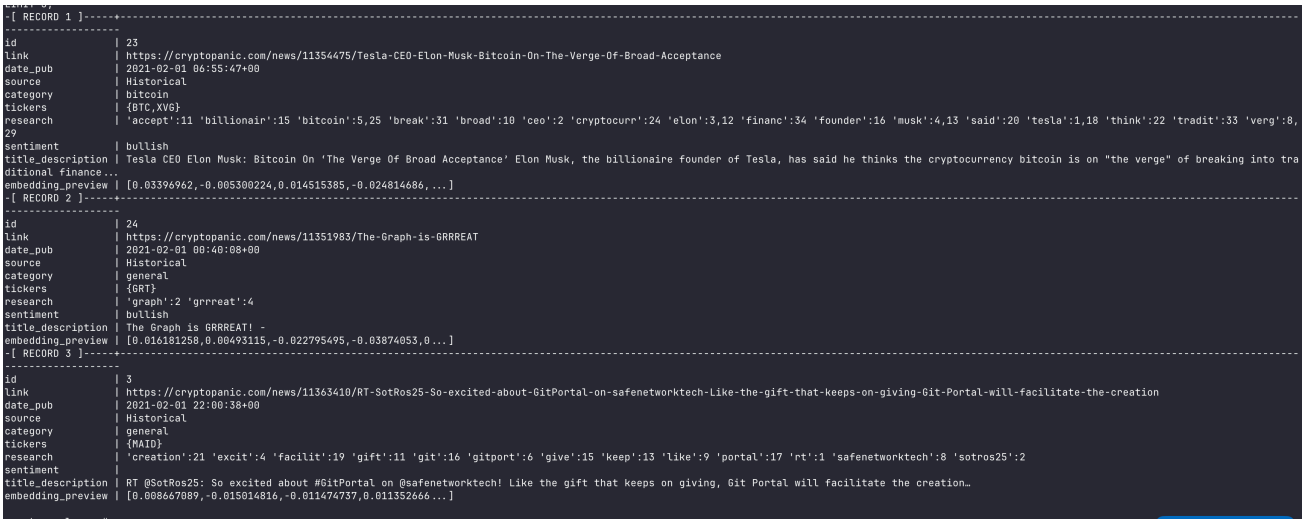
La participation au développement de la preuve de concept (Proof of Concept – PoC) du moteur de recherche s'est articulée autour de plusieurs tâches techniques, chacune correspondant à une étape importante dans la construction du projet.

3.1 CONCEPTION DU SCHÉMA SQL ET EXPLORATION DES DONNÉES (TASKS 10 ET 10.1)

Avant de concevoir la base de données, il a d'abord fallu analyser la structure des fichiers JSON contenant les articles. Pour cela, un script Python a été développé (Task 10.1) afin de parcourir un échantillon des données et de recenser l'ensemble des clés présentes. Cette phase d'exploration était essentielle pour comprendre le format des données et concevoir une structure de base de données adaptée.

Une fois cette analyse terminée, la conception du schéma SQL de la table crypto_news a pu commencer (Task 10). Plusieurs choix techniques ont été réalisés afin de préparer le projet aux futures fonctionnalités. Les listes de cryptomonnaies ont été stockées avec le type TEXT[], les dates avec le type TIMESTAMPTZ afin de gérer correctement les fuseaux horaires, et une colonne vector(4096) a été prévue pour accueillir les embeddings générés par l'intelligence artificielle.

L'un des aspects les plus techniques de cette étape a été la mise en place de colonnes calculées automatiquement (*GENERATED ALWAYS AS*) associées à la fonction tsvector de PostgreSQL. Cette approche permet de concaténer automatiquement le titre et la description des articles afin de créer un index textuel optimisé pour les recherches par mots-clés. Une contrainte d'unicité (*UNIQUE*) sur le lien et la date de publication a également été ajoutée afin d'éviter l'insertion de doublons.



3.2 DÉVELOPPEMENT DU PIPELINE D'EXTRACTION ETL (TASK 11)

Une fois la structure de la base de données finalisée, le développement du pipeline ETL (*Extract, Transform, Load*) a pu débuter. Un script Python a été réalisé afin de parcourir automatiquement les répertoires contenant les archives d'articles et d'importer les données dans PostgreSQL.

Cette étape a également nécessité la mise en place d'un traitement des cas particuliers.

Certaines descriptions contenaient par exemple la chaîne de caractères **"**NULL**"**, tandis que d'autres champs étaient absents ou vides. Une logique de nettoyage a donc été intégrée avant l'insertion en base afin de garantir la qualité des données.

Le pipeline a été conçu pour être idempotent, c'est-à-dire qu'il peut être relancé sans risque de dupliquer les données déjà importées. Cette propriété s'est révélée particulièrement utile lors des phases de test et de développement.

3.3 INTÉGRATION DE L'INTELLIGENCE ARTIFICIELLE : GÉNÉRATION DES EMBEDDINGS (TASK 12)

Afin de permettre au moteur de recherche de comprendre le sens des articles, leur contenu devait être converti en représentations vectorielles, appelées *embeddings*. Un script Python a donc été développé pour communiquer avec l'API du modèle d'intelligence artificielle Qwen3 et générer automatiquement ces vecteurs.

Cette partie du projet a mis en évidence plusieurs contraintes liées aux échanges avec une API distante. Une gestion des erreurs a été mise en place afin de traiter les éventuelles pertes de connexion, les indisponibilités du service ainsi que les limitations du nombre de requêtes autorisées (*rate limits*).

Au cours du développement, une panne du fournisseur d'IA a temporairement empêché la génération des embeddings. Afin de poursuivre le projet sans bloquer les développements en cours, une solution de contournement a été proposée : un script *mock* générant des vecteurs composés uniquement de zéros. Cette approche a permis de continuer à tester le pipeline d'insertion dans PostgreSQL ainsi que le reste de l'application, en attendant le rétablissement du service.

3.4 ARCHITECTURE ET OPTIMISATION DES INDEX SQL (TASK 13)

À mesure que le volume de données augmente, les performances de la base de données deviennent un enjeu important. L'objectif était donc de limiter les parcours complets de la table (*Sequential Scans*) afin de réduire le temps de réponse des recherches. Pour cela, plusieurs types d'index adaptés aux différents besoins du projet ont été étudiés et mis en place.

- GIN (Generalized Inverted Index) : utilisé pour accélérer les recherches sur les tableaux de *tickers* ainsi que la recherche textuelle. Ce type d'index fonctionne comme un dictionnaire inversé, ce qui permet de retrouver rapidement les articles contenant un mot-clé donné.

- BRIN (Block Range Index) : particulièrement adapté aux données triées chronologiquement, il permet d'optimiser les recherches par date tout en occupant très peu d'espace de stockage.

- HNSW (Hierarchical Navigable Small World) : utilisé pour la recherche vectorielle, cet index est au cœur du moteur de recherche sémantique puisqu'il permet de retrouver rapidement les vecteurs les plus proches d'une requête.

Au cours de cette étape, une contrainte technique liée à l'extension pgvector a également été rencontrée. En effet, celle-ci limite la création d'index HNSW à des vecteurs de 2 000 dimensions, alors que le modèle d'intelligence artificielle utilisé générait des embeddings de 4 096 dimensions.

Pour contourner cette limitation, une solution reposant sur la méthode Matryoshka Representation Learning (MRL) a été retenue. Les vecteurs étaient tronqués à 2 000 dimensions avant leur insertion dans PostgreSQL. Cette approche permet de conserver une qualité de recherche très proche de celle obtenue avec les vecteurs complets, tout en restant compatible avec les contraintes techniques de pgvector et en garantissant de bonnes performances lors des recherches.

3.5 INTERFACE DE DÉMONSTRATION CLI (TASK 13.5)

Une fois les principaux composants du projet développés, il a fallu concevoir une interface permettant de tester facilement le moteur de recherche. Une application en ligne de commande (CLI) a donc été développée afin d'interroger le système et d'afficher les résultats de manière claire.

Pour améliorer le rendu dans le terminal, la bibliothèque Python Rich a été intégrée. Elle permet d'afficher les résultats sous une forme plus lisible, avec notamment des couleurs, des tableaux, les pourcentages de correspondance (*Match*) ainsi que différentes métadonnées sur les articles trouvés.

Grâce à l'optimisation de la base de données, notamment avec l'utilisation de l'index HNSW, les recherches s'effectuent en moins de 50 millisecondes. Ce temps de réponse confirme l'efficacité de l'architecture mise en place et garantit une utilisation fluide de l'application.

3.6 DÉVELOPPEMENT D'UN MOTEUR DE RECHERCHE HYBRIDE (TASK 16)

La dernière étape du projet consistait à développer le moteur de recherche exploitant l'ensemble du pipeline précédemment mis en place. Lorsqu'une requête est saisie par l'utilisateur, un script Python génère tout d'abord son embedding, puis lance une recherche combinant plusieurs critères : le filtrage par *tickers*, une fenêtre temporelle de ±12 heures ainsi qu'une recherche sémantique basée sur la similarité des vecteurs.

Afin d'obtenir un classement pertinent des résultats, un algorithme de fusion appelé Reciprocal Rank Fusion (RRF) a été utilisé. Son rôle est de combiner les résultats issus de la recherche sémantique, calculée à partir de la distance cosinus entre les embeddings, avec ceux obtenus grâce à la recherche textuelle native de PostgreSQL. Le score final est obtenu à l'aide de la formule suivante :

$$Score = \frac{1}{60 + rank_v} + \frac{1}{60 + rank_t}$$

Cette méthode permet d'attribuer un score à chaque résultat en tenant compte de son classement dans les deux méthodes de recherche. Les articles les mieux positionnés dans les deux classements obtiennent ainsi un score plus élevé, ce qui améliore la pertinence des résultats proposés à l'utilisateur.

L'ensemble de cette logique est directement intégré au moteur de recherche, offrant une recherche à la fois rapide, pertinente et adaptée aux besoins du projet.

Vous retrouverez ci-dessous un rendu visuel du projet à cette étape :



PARTIE 4: DOCUMENTATION TECHNIQUE ET TRANSFERT DE COMPÉTENCES

En parallèle du développement, la rédaction de la documentation technique a occupé une place importante tout au long du projet. Chaque tâche réalisée était accompagnée de documents dédiés (*schema.md*, *storage.md*, *demo-guide.md*, etc.)

L'objectif était d'expliquer le « pourquoi » et le « comment » des choix techniques, en détaillant le fonctionnement du code, les exemples d'utilisation et l'architecture du projet. Cette documentation facilite la reprise du projet par un autre développeur, simplifie sa maintenance et garantit une meilleure évolutivité. Ce travail a également permis de mieux comprendre l'importance d'une documentation claire et à jour dans le développement d'un service informatique professionnel.

PARTIE 5: RIGUEUR DU VERSIONING ET RÉSOLUTION DE CONFLITS

Au-delà des aspects purement techniques, ce stage a permis de découvrir les bonnes pratiques liées à la gestion professionnelle du code source. Plusieurs situations concrètes ont mis en évidence l'importance d'un versioning rigoureux et d'une bonne organisation du travail collaboratif.

Par exemple, lors d'une tâche, du code contenant des variables codées en dur (*hardcoded*) a été intégré par erreur sur une mauvaise branche de développement. Afin de corriger cette situation sans altérer l'historique du projet, plusieurs commandes Git

avancées ont été utilisées, notamment git clean pour nettoyer l'espace de travail, git squash pour regrouper plusieurs commits en un seul et conserver un historique plus lisible, ainsi que git rebase pour replacer les modifications sur la branche appropriée.

D'autres situations similaires ont également permis de se familiariser avec les outils de gestion de versions et de mieux comprendre les bonnes pratiques utilisées dans un environnement de développement professionnel. Ces expériences ont renforcé l'autonomie acquise au cours du stage tout en soulignant l'importance d'un historique Git clair, cohérent et facilement exploitable.

PARTIE 6: L'INTELLIGENCE ARTIFICIELLE COMME OUTIL DE DÉVELOPPEMENT

L'intelligence artificielle a occupé une place importante tout au long du stage en tant qu'outil d'assistance au développement. Face à des notions parfois complexes en Data Engineering, les modèles de langage (LLM) ont permis d'obtenir rapidement des explications, de mieux comprendre certaines documentations techniques et de faciliter la prise en main de technologies encore peu connues.

L'environnement de développement intégrait également des agents IA, comme OpenCode, utilisés au quotidien pour assister le développement. Ils intervenaient notamment lors des revues de code (*code review*), de la recherche d'optimisations, de la résolution de bugs ou encore pour proposer des pistes d'amélioration. Ces outils ont permis de gagner du temps sur certaines tâches, tout en accélérant l'apprentissage de nouvelles technologies.

Toutefois, les propositions générées par l'intelligence artificielle n'étaient jamais appliquées sans vérification. Chaque solution devait être comprise, testée et adaptée aux besoins du projet avant d'être intégrée. Cette approche a permis de conserver la maîtrise de l'architecture, de la logique métier et de la qualité du code.

Enfin, l'utilisation de ces outils s'est toujours faite dans le respect des bonnes pratiques de sécurité. Aucune donnée sensible, information confidentielle ou clé d'API n'a été transmise aux modèles d'intelligence artificielle. Cette expérience a montré que l'IA constitue aujourd'hui un véritable outil d'aide au développement, à condition d'en faire un usage réfléchi, critique et sécurisé.

CONCLUSION

Cette première période de stage au sein de ZENG Expertise a constitué une expérience particulièrement formatrice. Elle a permis de mettre en pratique les connaissances acquises en BTS dans un contexte professionnel, tout en découvrant des problématiques concrètes liées au développement back-end, au Data Engineering et à l'intelligence artificielle.

Sur le plan technique, ce stage a été l'occasion de développer de nouvelles compétences à travers la conception d'un pipeline RAG. Les différentes missions réalisées ont permis de mieux comprendre le fonctionnement de PostgreSQL et de son extension pgvector, l'utilisation d'API d'intelligence artificielle, ainsi que les enjeux liés à l'optimisation des bases de données et des moteurs de recherche hybrides.

Au-delà des aspects techniques, cette expérience a également permis de découvrir les méthodes de travail utilisées en entreprise. L'utilisation quotidienne de Git et GitHub, le respect des bonnes pratiques de développement, la rédaction d'une documentation technique et le travail sur un projet structuré ont apporté une vision plus concrète des exigences du métier. Les différentes difficultés rencontrées au cours du stage ont aussi contribué à développer davantage d'autonomie et de rigueur dans la résolution de problèmes.

Ce stage confirme l'intérêt porté au domaine de la donnée et de l'intelligence artificielle, ainsi que l'envie de poursuivre dans cette voie. La poursuite d'études après le BTS, que ce soit en Licence Professionnelle, en BUT ou en école d'ingénieurs, permettra d'approfondir ces compétences et de se rapprocher progressivement de l'objectif professionnel de devenir Data Analyst, puis, à plus long terme, Data Scientist spécialisé en intelligence artificielle et en Machine Learning.